

Laporan Praktikum Kontrol Cerdas Week 4

Nama : Arjuna Kurniawan Kusuma Putra
NIM : 224308004
Kelas : TKA-6A
Akun Github : <https://github.com/kakjuna>
Student Lab Assistant : Rizky Putri Ramadhani (214308092)

1. Judul Percobaan: ***Reinforcement Learning for Autonomous Control***

2. Tujuan Percobaan:

- Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kontrol.
- Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
- Menggunakan OpenAI Gym sebagai platform simulasi lingkungan untuk pelatihan RL.
- Melatih dan menguji agen RL agar dapat mengendalikan lingkungan secara mandiri.
- Memanfaatkan GitHub untuk version control serta mendokumentasikan hasil praktikum.

3. Landasan Teori:

Reinforcement learning adalah metode pembelajaran yang berfokus pada pemetaan situasi untuk menentukan tindakan dengan tujuan memaksimalkan sinyal penghargaan yang bisa diperoleh dari lingkungan (Nguyen, et al., 2018). Tujuan utama dari Reinforcement learning adalah menggunakan data observasi dari interaksi dengan lingkungan untuk mengambil tindakan yang dapat memaksimalkan hasil sekaligus meminimalkan risiko (Wijoyo, et al., 2024). Algoritma ini bekerja secara iteratif, di mana agen belajar melalui interaksi dengan lingkungannya.

Proses pembentukan model dalam algoritma ini terdiri dari beberapa tahapan. Agen pertama-tama mengamati masukan dari lingkungan, kemudian mengambil tindakan yang dianggap paling sesuai. Setelah tindakan tersebut dilakukan, agen menerima "reward" atau umpan balik dari lingkungan. Selanjutnya, agen kembali melakukan observasi dan mengambil keputusan baru berdasarkan pengalaman sebelumnya, dengan tujuan meningkatkan akurasi keputusan melalui penguatan dari lingkungan.

Salah satu algoritma dalam Reinforcement learning adalah Deep Q-Network (DQN), yang menggabungkan pendekatan Q-Learning dengan jaringan saraf dalam (deep neural network) (Fuad, 2022). DQN

menggunakan jaringan saraf untuk mendekati fungsi Q, yaitu fungsi yang memetakan keadaan (state) dan tindakan (action) ke nilai yang mengukur seberapa baik suatu tindakan akan berdampak dalam jangka panjang. Q-Learning sendiri termasuk metode model-free, yang berarti tidak memerlukan informasi lengkap mengenai kondisi lingkungan (environment). Beberapa jenis lingkungan yang umum digunakan dalam penerapan RL antara lain LunarLander-v2, MountainCar-v0, dan CartPole.

40

4. Analisis dan Diskusi:

- Analisis

Pada percobaan yang dilakukan, algoritma Deep Q-Network (DQN) diterapkan untuk melatih agen dalam dua lingkungan berbeda, yaitu MountainCar-v0 dan CartPole-v1. Di lingkungan MountainCar-v0, agen ditugaskan untuk menggerakkan mobil yang terjebak di lembah menggunakan momentum agar dapat mencapai puncak bukit. Tantangan utama dalam tugas ini adalah mobil tidak cukup kuat untuk langsung mendaki bukit, sehingga agen harus belajar mengayunkan mobil maju mundur untuk mendapatkan momentum yang cukup. Reward diberikan berdasarkan kondisi lingkungan; agen akan mendapatkan reward sebesar 100 jika berhasil mencapai puncak, dan menerima reward negatif jika gagal (misalnya, saat waktu habis). Agen dilengkapi dengan jaringan saraf sederhana yang memiliki dua lapisan tersembunyi serta menggunakan strategi epsilon-greedy untuk eksplorasi. Parameter epsilon_min ditetapkan sebesar 0.01 dan epsilon_decay sebesar 0.995. Selain itu, parameter lain seperti gamma (faktor diskon), epsilon (rate eksplorasi), dan epsilon_decay (penurunan epsilon) juga digunakan dalam proses pengambilan keputusan dan pembelajaran. Sementara itu, di lingkungan CartPole-v1, agen bertugas menjaga keseimbangan sebuah tiang yang berdiri di atas gerobak dengan menggerakkan gerobak ke kiri atau ke kanan agar tiang tidak jatuh. Reward diberikan untuk setiap langkah di mana agen berhasil menjaga tiang tetap seimbang, dan episode akan

berakhir jika tiang jatuh atau batas waktu tercapai. Agen mendapatkan reward positif ketika tiang tetap stabil dan reward negatif ketika tiang jatuh atau waktu habis. Dengan `epsilon_decay` yang cepat, agen beralih dari eksplorasi ke eksploitasi dengan lebih cepat, sehingga dapat membuat keputusan yang lebih konsisten berdasarkan pengalaman sebelumnya. Parameter seperti `gamma`, `epsilon`, dan `epsilon_decay` juga berperan dalam pengambilan keputusan dan proses pembelajaran. Dengan batas maksimal 1000 episode, agen memiliki banyak kesempatan untuk belajar dan mengoptimalkan kebijakan yang lebih baik.

- Diskusi

Dari hasil praktikum yang dilakukan, terlihat perbedaan dalam pembelajaran antara lingkungan `CartPole-v1` dan `MountainCar-v0`, yang menunjukkan bagaimana karakteristik setiap lingkungan memengaruhi cara agen belajar. Pada `CartPole-v1`, reward diberikan secara positif untuk setiap langkah yang berhasil, sehingga agen menerima reward secara terus-menerus, memberikan umpan balik langsung untuk memperbaiki strategi tindakannya. Hal ini mempercepat proses pelatihan dan memudahkan algoritma menemukan strategi yang efektif. Karena itu, `CartPole` lebih mudah dipelajari dengan pendekatan eksplorasi yang lebih cepat dan penggunaan replay buffer yang lebih kecil, sebab agen memperoleh pengalaman positif lebih cepat. `CartPole` relatif sederhana sehingga sangat cocok untuk eksperimen awal dalam reinforcement learning dan untuk menguji algoritma dasar seperti Q-learning atau DQN. Sebaliknya, pada `MountainCar-v0`, reward baru diberikan secara signifikan ketika agen berhasil mencapai puncak, sehingga agen perlu mengembangkan strategi jangka panjang, seperti mengumpulkan momentum melalui aksi yang berulang. Reward yang diterima hanya -1 hingga agen mencapai puncak, yang berarti tidak ada umpan balik positif sampai tujuan tercapai, sehingga proses pelatihan menjadi lebih lambat. Lingkungan ini membutuhkan lebih banyak eksplorasi dan strategi yang lebih cerdas, menjadikannya cocok untuk menguji algoritma DQN serta varian yang lebih kompleks. `MountainCar` lebih sulit untuk dipelajari,

membutuhkan replay buffer yang lebih besar serta pendekatan pelatihan yang lebih sabar. Agen memerlukan lebih banyak data untuk memahami cara mencapai tujuannya, sehingga teknik seperti Target Network Update dan epsilon decay yang lebih lambat menjadi lebih efektif dalam lingkungan ini.

5. *Assignment:*

Pada praktikum minggu keempat ini, telah dilakukan percobaan dan perbandingan performa agen Deep Q-Network (DQN) pada dua lingkungan yang berbeda, yaitu CartPole-v1 dan MountainCar-v0, dengan menggunakan pustaka OpenAI Gym, OpenCV, serta TensorFlow. Agen DQN yang digunakan terdiri dari dua neural network utama: Q-Network, yang bertugas memperkirakan nilai Q dan menentukan tindakan optimal berdasarkan kondisi lingkungan, serta Target Network, yang diperbarui secara berkala untuk menjaga stabilitas pelatihan dengan melakukan pembaruan bobot secara berkala.

Pada eksperimen pertama dengan CartPole-v1, agen ditugaskan untuk menjaga keseimbangan tiang di atas gerobak selama mungkin, dengan mendapatkan reward +1 untuk setiap langkah yang berhasil dilalui. Reward yang konsisten ini memungkinkan proses pembelajaran menjadi lebih cepat. Parameter yang digunakan antara lain epsilon decay (0.995), replay buffer (2000), batch size (64), dan pembaruan Target Network setiap 10 langkah. Hasil eksperimen menunjukkan bahwa pada awalnya agen melakukan banyak eksplorasi karena nilai epsilon yang masih tinggi (1.0). Namun, seiring waktu dengan menurunnya nilai epsilon, agen mulai beralih ke eksploitasi kebijakan terbaik yang telah dipelajari. Dengan semakin banyaknya pengalaman yang dikumpulkan, agen mampu meningkatkan skornya dan menjaga keseimbangan tiang lebih lama. Pembaruan Target Network secara berkala juga membantu menjaga stabilitas pelatihan, sehingga nilai Q tidak berubah secara tiba-tiba.



Sementara itu, pada eksperimen kedua yang dilakukan di lingkungan MountainCar-v0, tantangannya lebih besar karena reward hanya diberikan ketika agen berhasil mencapai puncak bukit. Tantangan

utama di lingkungan ini adalah agen harus menemukan strategi yang tepat untuk memanfaatkan momentum agar bisa mencapai tujuan. Untuk menyesuaikan dengan tantangan tersebut, epsilon decay dibuat lebih lambat agar agen memiliki lebih banyak kesempatan mencoba berbagai strategi sebelum beralih ke eksploitasi. Replay buffer diperbesar menjadi 5000, dan reward sebesar +100 ditambahkan ketika agen mencapai puncak untuk memberikan sinyal yang lebih jelas mengenai tujuan akhirnya.

Pada awal eksperimen, agen mengalami kesulitan karena tidak ada reward langsung yang diberikan untuk setiap langkah, sehingga membuat strategi eksplorasi menjadi lebih rumit. Namun, seiring bertambahnya pengalaman, agen mulai memahami bahwa dengan mengayunkan mobil maju-mundur, ia dapat memanfaatkan momentum untuk mencapai puncak dengan lebih efisien. Setelah beberapa ratus episode, agen mulai lebih sering mencapai tujuannya dan menyelesaikan tugas dengan lebih cepat.

6. Data dan Output Hasil Pengamatan:

No	Variabel	Cartpole-v1	MountainCar-v0
1.	Waktu Pelatihan	CartPole lebih cepat mencapai performa optimal	MountainCar membutuhkan lebih banyak waktu untuk mencapai keberhasilan yang stabil
2.	Jumlah Episode Maksimum	CartPole dilatih hingga 1000 episode <pre> _name__ == '__main__': env = gym.make('CartPole-v1') state_size = env.observation_space.shape[0] action_size = env.action_space.n agent = DQNAgent(state_size, action_size) episodes = 1000 batch_size = 64 target_update_interval = 10 # Interval to u </pre>	MountainCar dilatih hingga 1000 episode <pre> _name__ == '__main__': env = gym.make('MountainCar-v0') state_size = env.observation_space.shape[0] action_size = env.action_space.n agent = DQNAgent(state_size, action_size) episodes = 1000 batch_size = 64 target_update_interval = 10 # Interval to </pre>
3.	Skor dari tiap episode	Skor bervariasi dari beberapa episode <pre> Test Episode: 3, Score: 83 Test Episode: 4, Score: 48 Test Episode: 5, Score: 55 Test Episode: 6, Score: 452 Test Episode: 7, Score: 37 Test Episode: 8, Score: 80 Test Episode: 9, Score: 35 Test Episode: 10, Score: 105 Test Episode: 11, Score: 20 Test Episode: 12, Score: 102 Test Episode: 13, Score: 39 </pre>	Skor awal mencapai 199 karena maksimal langkah dalam satu episode adalah 200 <pre> Test Episode: 2, Score: 199, Test Episode: 3, Score: 199, Test Episode: 4, Score: 199, Test Episode: 5, Score: 199, Test Episode: 6, Score: 199, Test Episode: 7, Score: 199, Test Episode: 8, Score: 199, Test Episode: 9, Score: 199, Test Episode: 10, Score: 199, Test Episode: 11, Score: 199, Test Episode: 12, Score: 199, Test Episode: 13, Score: 199, Test Episode: 14, Score: 199, </pre>

4.	Epsilon	Nilai epsilon (ϵ) menurun seiring dengan proses agen <pre> Epsilon: 1.00 Epsilon: 1.00 Epsilon: 0.99 Epsilon: 0.99 Epsilon: 0.99 Epsilon: 0.98 Epsilon: 0.98 , Epsilon: 0.97 , Epsilon: 0.97 , Epsilon: 0.96 , Epsilon: 0.96 , Epsilon: 0.95 , Epsilon: 0.95 , Epsilon: 0.94 , Epsilon: 0.94 , Epsilon: 0.93 , Epsilon: 0.93 Epsilon: 0.92 , Epsilon: 0.92 , Epsilon: 0.91 , Epsilon: 0.91 , Epsilon: 0.90 , Epsilon: 0.90 </pre>	Nilai epsilon (ϵ) menurun seiring dengan proses agen <pre> Epsilon: 0.95 Epsilon: 0.95 Epsilon: 0.94 Epsilon: 0.94 Epsilon: 0.93 Epsilon: 0.93 Epsilon: 0.92 Epsilon: 0.92 Epsilon: 0.91 Epsilon: 0.91 Epsilon: 0.90 Epsilon: 0.90 Epsilon: 0.90 Epsilon: 0.89 </pre>
5.	Kinerja Agen	Kinerja yang lebih stabil dengan skor yang lebih tinggi	Masih menghadapi tantangan dalam mencapai puncak
6.	Kondisi Berhasil	Episode berakhir jika tiang jatuh, reward akan positif	Episode berakhir jika mobil mencapai puncak bukit (flag)
7.	Hasil		

7. Kesimpulan:

Berdasarkan praktikum dan analisis yang telah dilakukan, maka dapat diambil kesimpulan yaitu:

- MountainCar-v0 lebih menantang dan cocok untuk menguji algoritma reinforcement learning yang lebih kompleks karena memerlukan strategi jangka panjang. Namun, proses pelatihannya bisa memakan waktu lebih lama karena reward tidak diperoleh secara langsung.
- CartPole-v1 lebih mudah dan cepat dipelajari, sehingga cocok untuk eksperimen awal dalam pengembangan algoritma reinforcement learning. Namun, lingkungan ini tidak memberikan tantangan yang signifikan bagi algoritma yang lebih canggih. Agen menggunakan pendekatan DQN dengan replay buffer untuk memori, fungsi nilai Q di-*approximate* oleh jaringan saraf (*neural network*), dan *epsilon-greedy* untuk eksplorasi.
- Agen memulai dengan nilai epsilon tinggi (1.0) dan secara bertahap menurunkannya, memungkinkan agen untuk lebih banyak melakukan eksploitasi seiring dengan waktu.

8. Saran:

Untuk meningkatkan agar performa agen DQN lebih baik bisa menerapkan *Target Network* untuk meningkatkan stabilitas dan mencegah model dari *overfitting* terhadap pola jangka pendek, dengan cara memperbarui target *network* secara periodik. strategi epsilon *decay* yang lebih adaptif, seperti menyesuaikannya berdasarkan performa, dapat memperbaiki keseimbangan eksplorasi dan eksploitasi. dapat mengoptimalkan *hyperparameter* seperti gamma, learning_rate, dan epsilon_decay untuk meningkatkan performa. Menggunakan Double DQN akan membantu menghindari masalah overestimation. MountainCar, pendekatan lain seperti *actor-critic methods* atau *policy-based reinforcement learning* dapat dicoba untuk meningkatkan efisiensi pembelajaran.

9. Daftar Pustaka

- Cahya, F., Riana, D. & Hadiyanti, S., 2021. Klasifikasi Penyakit Mata Menggunakan Convolutional Neural Network (CNN). *SISTEMASI*, p. 618.
- Fuad, M. R. T., 2022. Adaptive Deep Q-Network Algorithm with Exponential Reward Mechanisme for Traffic Control in Urban Intersection Networks. *Sustain*, Volume 14, p. 21.
- Malik, M., 2021. DETEKSI SUHU TUBUH DAN MASKER WAJAH DENGAN MLX90614, OPENCV, KERAS/TENSORFLOW, DAN DEEP LEARNING.. *Jurnal Engine: Energi, Manufaktur, dan Material*, p. 19.
- Nguyen, N. D., Nguyen, T. & Nahavandi, S., 2018. System Design Perspective for Human-Level Agent Using Deep Reinforcement Learning: A Survey. *IEEE Acces* , Volume 1, p. 99.
- Pumsirirat, 2018. Credit Card Fraud Detection using Deep Learning based on Auto-Encoder International Journal of Advanced. *ComputerScience and Applications (IJACSA)*, Volume 9(1), pp. 1825-1844.
- Rahman, C. R. et al., 2020. Identification and recognition of rice diseases and pests using convolutional neural networks.. *Biosystems Engineering*, pp. 112-120.
- Santoso, A. & Ariyanto, G., 2018. IMPLEMENTASI DEEP LEARNING BERBASIS KERAS UNTUK PENGENALAN WAJAH. *Jurnal Tekning Elektro*.
- Wijoyo , A. et al., 2024. Pembelajaran Machine Learning. *Jurnal Ilmu Komputer dan Science*, Volume 3, p. 2.

